

## SPRINT 4: CREACIÓN DE BASES DE DATOS

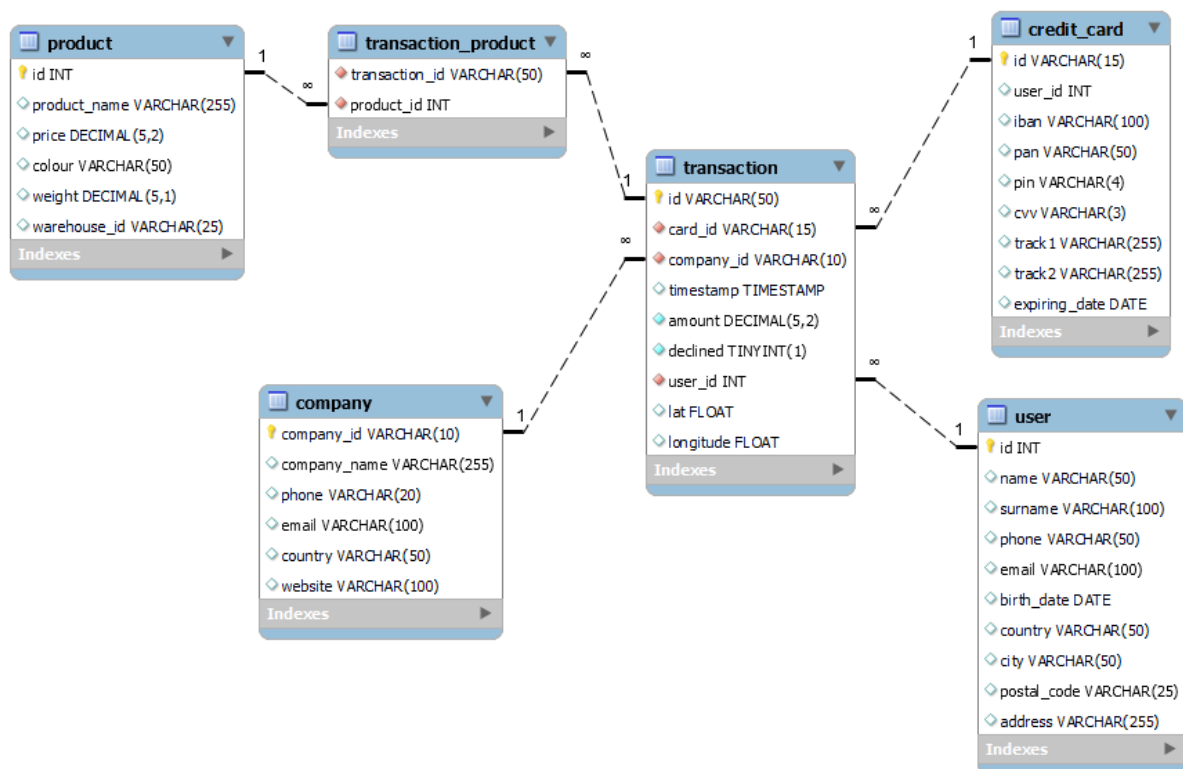
Descarga los archivos CSV, estúdielos y diseña una base de datos con un esquema de estrella que contenga, al menos, 4 tablas.

Los archivos CSV contenían registros sobre las transacciones, las empresas que participan en dichas transacciones, las tarjetas de crédito utilizadas, los usuarios que las realizaron (de tres países: Reino Unido, Estados Unidos y Canadá) y los productos vendidos. He creado una base de datos llamada *operations* y las tablas correspondientes para importar los datos de los archivos CSV usando LOAD DATA INFILE (véase script estructura\_operationsdb.sql para más detalles).

Los registros de transacciones contenían varios identificativos de productos por transacción en una única columna, cosa que complicaba filtrar los datos de un único producto. Para solucionarlo, he creado una tabla nueva (transaction\_product) para los ids de transacciones y los ids de productos. A continuación, he transformado la columna de product\_ids de transactions.csv para separar cada producto de una transacción en una fila. \*

He escogido los tipos de datos de las variables en función de la información que contenían. Por ejemplo, las columnas que contenían fechas las he definido como DATE, las que contenían números decimales (amount, price y weight) las he definido como DECIMAL, las que contenían id's de usuario/producto como INT, etc. \*\*

En este modelo tenemos la tabla de hechos transaction, que conecta con las tablas dimensión credit\_card \*\*\*, user y company con una relación N:1 (transaction N:1 dimensión). Para relacionar transaction con dimensión product tenemos la tabla intermedia transaction\_product, que conecta N:1 con transaction y N:1 con product (véase diagrama a continuación).



\* **NOTA 1:** He realizado la transformación de productos por fila en MySQL. Para conseguir esta modificación, he necesitado los siguientes pasos:

- Crear una tabla temporal para cargar las columnas transaction\_id y product\_ids (en formato VARCHAR, al ser múltiples valores separados por coma; no se detectaría como INT)
- Importar las columnas mencionadas a esta tabla temporal

```
CREATE TEMPORARY TABLE transaction_product_temp (
    transaction_id VARCHAR(50),
    product_ids VARCHAR(100)
);

LOAD DATA INFILE 'C:/ProgramData/MySQL/MySQL Server 8.0/Uploads/transactions.csv'
INTO TABLE transaction_product_temp
FIELDS TERMINATED BY ','
LINES TERMINATED BY '\r\n'
IGNORE 1 ROWS
(transaction_id, @dummy, @dummy, @dummy, @dummy, @dummy, product_ids, @dummy, @dummy, @dummy);
```

- Separar los productos en filas separadas e insertar los registros en la tabla transaction\_product:
  - Creamos una columna, llamada n, para establecer un índice interno que nos ayudará a separar cada registro de la columna product\_ids; la relacionamos con la tabla temporal con los datos de product\_ids (en VARCHAR) con la condición de que la longitud product\_ids – longitud product\_ids (sin comas) sea superior o igual a n-1. Por ejemplo:
    - Product\_ids 71, 41 → char\_length 6 – char\_length 5 = 1 ≥ n-1
      - n=2 porque tenemos dos registros de products\_ids
    - Product\_ids 47, 37, 11, 1 → char\_length 13 – char\_length 10 = 3 ≥ n-1
      - n=4 porque tenemos cuatro registros de product\_ids
  - Separamos los registros de product\_ids con SUBSTRING\_INDEX. Por ejemplo:
    - Product\_ids 71, 41
      - n=1 → 71
      - n=2 → 71, 41 → SUBSTRING\_INDEX ((71, 41), ',' -1) → 41
      - n=3: nada porque no se cumpliría que la longitud de caracteres es superior que n-1 → 1 no es superior que 2
    - Product\_ids 47, 37, 11, 1
      - n=1 → 47
      - n=2 → 47, 37 → SUBSTRING\_INDEX ((47, 37), ',' -1) → 37
      - n=3 → 47, 37, 11 → SUBSTRING\_INDEX ((47, 37, 11), ',' -1) → 11
      - n=4 → 47, 37, 11, 1 → SUBSTRING\_INDEX ((47, 37, 11, 1), ',' -1) → 1

Si el número generado (n) es menor o igual al número de elementos en la lista, se extrae el elemento correspondiente de la cadena product\_ids. Si no, esa fila de la subconsulta numbers no contribuirá a la extracción de elementos para esa fila de la tabla.

```

INSERT INTO transaction_product (transaction_id, product_id)
SELECT transaction_id,
        SUBSTRING_INDEX(SUBSTRING_INDEX(product_ids, ',', numbers.n), ',', -1) AS product_id
FROM transaction_product_temp
JOIN ( SELECT 1 AS n
      UNION ALL SELECT 2
      UNION ALL SELECT 3
      UNION ALL SELECT 4 ) AS numbers
ON CHAR_LENGTH(product_ids) - CHAR_LENGTH(REPLACE(product_ids, ',', '')) >= n - 1;

```

- Eliminar la tabla temporal creada

```
DROP TEMPORARY TABLE transaction_product_temp;
```

**\*\* NOTA 2:** Para garantizar una carga precisa de los datos, he agregado cláusulas SET para ajustar datatype de las columnas del archivo CSV de origen.

- Para modificar el formato de fechas de origen a YYYY-MM-DD (DATE): STR\_TO\_DATE; modificación similar para birth\_date (tabla user)

```

LOAD DATA INFILE 'C:/ProgramData/MySQL/MySQL Server 8.0/Uploads/credit_cards.csv'
INTO TABLE credit_card
FIELDS TERMINATED BY ','
LINES TERMINATED BY '\n'
IGNORE 1 ROWS
(id, user_id, iban, pan, pin, cvv, track1, track2, @expiring_date)
SET expiring_date=STR_TO_DATE(@expiring_date, '%c/%d/%y');

```

- Para quitar el símbolo de \$ de la columna price y, así, se pueda detectar como DECIMAL: REPLACE

```

LOAD DATA INFILE 'C:/ProgramData/MySQL/MySQL Server 8.0/Uploads/products.csv'
INTO TABLE product
FIELDS TERMINATED BY ','
LINES TERMINATED BY '\n'
IGNORE 1 ROWS
(id, product_name, @price, colour, weight, warehouse_id)
SET price=REPLACE(@price, '$', '');

```

**\*\*\* NOTA 3:** La tabla credit\_card contiene el identificador de los usuarios que son propietarios de las tarjetas de crédito. No he establecido una relación entre las tablas credit\_card y user ya que se formaría una relación cíclica en mi base de datos.

## NIVEL 1

**Ejercicio 1.** Realiza una subconsulta que muestre a todos los usuarios con más de 30 transacciones utilizando al menos 2 tablas.

Subconsulta: cuento la cantidad de registros en la tabla transaction con la condición de que los identificadores correspondan a los presentes en la tabla user. El conteo se realiza en función de los usuarios (GROUP BY user.id).

Como filtro, aplico que la cantidad de transacciones sea superior a 30.

Selecciono todos los campos de la tabla user para tener datos personales completos de los usuarios.

```
SELECT u.*,
       (SELECT COUNT(id)
        FROM transaction t
        WHERE t.user_id = u.id) AS num_transacciones
FROM user u
GROUP BY u.id
HAVING num_transacciones > 30;
```

Obtenemos un total de cuatro usuarios que cumplen el criterio establecido: Lynn Riddle (id 92), Ocean Nelson (id 267), Hedwig Gilbert (id 272) y Kenyon Hartman (id 275). Sus datos personales y la cantidad de transacciones realizadas por cada uno de ellos se muestran en la tabla a continuación.

id	name	surname	phone	email	birth_date	country	city	postal_code	address	num_transacciones
92	Lynn	Riddle	1-387-885-4...	vitae.aliquet@outl...	1984-09-21	United States	Bozeman	61871	P.O. Box 712, ...	39
267	Ocean	Nelson	079-481-2745	aenean@yahoo.c...	1991-12-26	Canada	Charlottetown	85X 3P4	Ap #732-8357...	52
272	Hedwig	Gilbert	064-204-8788	sem.eget@icloud....	1991-04-16	Canada	Tuktoyaktuk	Q4C 3G7	P.O. Box 496, ...	76
275	Kenyon	Hartman	082-871-7248	convallis.ante.lect...	1982-08-03	Canada	Richmond	R8H 2K2	8564 Facilisi. St.	48

**Ejercicio 2.** Muestra el promedio de las transacciones por IBAN de las tarjetas de crédito en la compañía Donec Ltd. utilizando al menos 2 tablas.

En la tabla de transacciones tenemos id\_company pero no su nombre, por lo que tenemos que recurrir a la tabla company mediante una subconsulta para conocer el identificador de la compañía Donec Ltd.

Una vez sabemos el id, podemos calcular el promedio de las transacciones de esta compañía en función de las tarjetas de crédito utilizadas (GROUP BY card\_id).

Al tener ya el promedio por tarjeta, solo falta relacionarlo con la tabla credit\_card para tener el número de IBAN asociado a la tarjeta.

```
WITH avg_trans_card AS
(
  SELECT card_id, ROUND(AVG(amount),2) AS avg_amount
  FROM transaction
  WHERE company_id = (SELECT company_id
                     FROM company
                     WHERE company_name='Donec Ltd')
  GROUP BY card_id
)
SELECT iban, atc.avg_amount AS promedio_transaccion
FROM credit_card cc
JOIN avg_trans_card atc
ON cc.id=atc.card_id;
```

En este caso, la compañía Donec Ltd. tenía tan solo dos transacciones y las dos se realizaron con la misma tarjeta de crédito. Por tanto, como resultado obtenemos un número iban (mostrado en la tabla) con un promedio de 203.72 euros.

iban	promedio_transaccion
PT87806228135092429456346	203.72

## NIVEL 2

**Crea una nueva tabla que refleje el estado de las tarjetas de crédito basado en si las últimas tres transacciones fueron declinadas.**

Para crear una tabla que muestre el estado de las tarjetas, debemos conseguir las últimas tres transacciones realizadas con las tarjetas. Para ello, seleccionamos información relevante, como es el id de la tarjeta, timestamp (fecha y hora de la transacción) y declined (0: aceptada, 1: rechazada).

Dado que el número de transacciones por tarjeta varían, debemos aplicarle un “índice” interno a cada fila de transacción de una determinada tarjeta con la función ROW\_NUMBER ().

Al usar PARTITION BY card\_id, estamos indicando a la función que separe las asignaciones de números secuenciales para cada tarjeta individualmente. Es decir, cuando terminan las transacciones de una tarjeta y comienzan las de otra, el índice se reinicia a 1 para la nueva tarjeta. Esto asegura que cada tarjeta tenga su propio conjunto de índices únicos para sus transacciones.

Además, al especificar ORDER BY timestamp DESC, estamos ordenando las transacciones dentro de cada grupo de tarjeta de más recientes a las más antiguas.

Para determinar si una tarjeta está activa o no, hay que considerar las 3 transacciones más recientes de cada tarjeta (row\_transaction <= 3); por tanto, en la tabla card\_status únicamente incluiremos aquellas tarjetas que tengan al menos 3 transacciones registradas (COUNT card\_id = 3). La razón detrás de este requisito es asegurarnos de tener suficiente información para tomar una decisión precisa sobre el estado de la tarjeta.

Esto quiere decir que aquellas tarjetas que tengan un total de 1 o 2 transacciones no cumplen con el criterio por el siguiente motivo:

- Dos transacciones: aunque ambas transacciones sean rechazadas, no podemos concluir que la tarjeta está inactiva. Faltaría saber si la tercera transacción de esa tarjeta sería aceptada o no.
- Una transacción: aunque la única transacción esté rechazada, desconocemos si es debido a que la tarjeta está inactiva u otro motivo. Faltarían dos transacciones más para poder evaluar con mayor precisión el estado de la tarjeta.

En la tabla creada tendremos dos columnas, la primera con el identificador de la tarjeta y la segunda con el estado de la tarjeta: ‘operativa’ o ‘inoperativa’ (asignamos el estado con CASE).

- Si las tres transacciones son rechazadas, la suma de declined sería 3, por tanto ‘inoperativa’
- Si hay una o dos transacciones rechazadas de las tres a considerar, la suma de declined sería <= 2, por tanto ‘operativa’

Todas aquellas tarjetas que actualmente tengan una o dos transacciones (266 tarjetas) se podrán añadir más adelante a la tabla card\_status si obtenemos registros de dos o una transacción más, respectivamente.

```
CREATE TABLE IF NOT EXISTS card_status (
    id_tarjeta VARCHAR(15),
    estado_tarjeta VARCHAR(50)
);

INSERT INTO card_status (id_tarjeta, estado_tarjeta)
(WITH trans_card AS
(
    SELECT card_id,
        timestamp,
        declined,
        ROW_NUMBER() OVER (PARTITION BY card_id ORDER BY timestamp DESC) AS row_transaction
    FROM transaction
)
SELECT card_id AS id_tarjeta,
    CASE
        WHEN SUM(declined) <= 2 THEN 'operativa'
        ELSE 'inoperativa'
    END AS estado_tarjeta
FROM trans_card
WHERE row_transaction <= 3
GROUP BY id_tarjeta
HAVING COUNT(id_tarjeta) = 3
);
```

### Ejercicio 1. ¿Cuántas tarjetas están activas?

Una vez tenemos creada la tabla con el estado de las tarjetas, contamos cuántas están operativas.

```
SELECT COUNT(*) AS 'cantidad tarjetas activas'
FROM card_status
WHERE estado_tarjeta='operativa';
```

Como resultado, obtenemos 9 tarjeta activas. Cabe destacar que en la tabla card\_status tenemos un total de nueve tarjetas, que son las únicas que cumplen con todos los criterios establecidos. Por tanto, todas las tarjetas presentes en card\_status están activas.

cantidad tarjetas activas
9

## NIVEL 3

### Ejercicio 1. Necesitamos conocer el número de veces que se ha vendido cada producto.

En mi informe he querido separar en columnas separadas la cantidad de transacciones aceptadas y la cantidad de rechazadas para cada producto, además del total de ventas.

Con la tabla transaction\_product podemos saber la cantidad total de transacciones que se han registrado para un determinado producto; pero, tal como he diseñado la tabla, no podemos distinguir

si esas transacciones fueron aceptadas o rechazadas. Para ello, tenemos que recurrir a la tabla transaction mediante una JOIN.

Para calcular la cantidad de transacciones, utilizo la función SUM con la condición descrita en CASE.

- En la columna ventas.cant\_acept aplico la condición de que todas las transacciones aceptadas (declined 0) tengan valor 1 y las rechazadas 0, por lo que sumando las veces que aparece cada producto obtenemos el total de ventas exitosas.
- En la columna ventas.cant\_rech aplico la condición de que todas las transacciones rechazadas (declined 1) tengan valor 1 y las aceptadas 0, por lo que la suma daría el total de ventas rechazadas para cada producto.

En la columna ventas.cant\_tot aplico la función COUNT sin ninguna condición para calcular la cantidad total de transacciones registradas para cada producto.

Una vez tenemos esta información, podemos relacionarla con la tabla product para conocer los detalles de cada producto mediante LEFT JOIN, ya que hay productos sin ninguna transacción registrada. Para evitar tener valores NULL para los productos sin ventas, aplico la función IFNULL ().

```
WITH ventas AS
(
  SELECT product_id,
         SUM(CASE WHEN declined = 0 THEN 1 ELSE 0 END) AS cant_acept,
         SUM(CASE WHEN declined = 1 THEN 1 ELSE 0 END) AS cant_rech,
         COUNT(product_id) AS cant_tot
  FROM transaction_product tp
  JOIN transaction t
  ON tp.transaction_id = t.id
  GROUP BY product_id
)
SELECT p.*,
       IFNULL(v.cant_acept,0) AS cantidad_vendida,
       IFNULL(v.cant_rech,0) AS cantidad_rechazada,
       IFNULL(cant_tot,0) AS cantidad_total
FROM product p
LEFT JOIN ventas v
ON v.product_id=p.id;
```

Con esta consulta, obtenemos una tabla con 100 registros, lo que corresponde a la cantidad total de productos registrados en la tabla product. Al examinar la tabla, vemos que algunos productos tienen cero transacciones registradas (por ejemplo, el producto con el ID 4). Esto significa que no se ha realizado ninguna transacción relacionada con este producto hasta el momento.

id	product_name	price	colour	weight	warehouse_id	cantidad_vendida	cantidad_rechazada	cantidad_total
1	Direwolf Stannis	161.11	#7c7c7c	1.0	WH-4	51	10	61
2	Tarly Stark	9.24	#919191	2.0	WH-3	56	9	65
3	duel tourney Lannister	171.13	#d8d8d8	1.5	WH-2	43	8	51
4	warden south duel	71.89	#111111	3.0	WH-1	0	0	0
5	skywalker ewok	171.22	#dbdbdb	3.2	WH-0	42	7	49